

CMRPI – Espace Maroc Cyberconfiance (EMC)

Projet PFA N°10 – Tableau de bord décisionnel des signalements EMC Helpline

LIVRABLE DU JALON 2

Préparation des données et calcul des indicateurs

Période du jalon : 1er – 15 août 2026

Projet : Tableau de bord décisionnel et analytique des signalements EMC Helpline

Structure : CMRPI – Espace Maroc Cyberconfiance

Domaine : Analyse de données

Livrable préparé dans le cadre du Projet de Fin d'Année (PFA)

1. Objectif du Jalon 2

Le deuxième jalon a pour objectif de passer de la définition des indicateurs réalisée au Jalon 1 à leur mise en œuvre sur les données disponibles. Le travail porte sur trois étapes principales : le nettoyage des données avec **pandas**, le calcul des KPI définis au Jalon 1 et la production des premiers graphiques avec **Plotly**.

Le document de cadrage précise que le livrable du Jalon 2 est un script Python permettant de calculer les KPI et de générer les graphiques de base. Le point de contrôle consiste notamment à vérifier l'exactitude des calculs sur des exemples contrôlés manuellement.

Périmètre : ce rapport présente le traitement réalisé sur le jeu de données 2025, les résultats obtenus pour les KPI 1 à 6f, ainsi que les contrôles statistiques associés.

2. Jeu de données utilisé

Le jeu de données contient **138 signalements** couvrant l'année 2025, du 1er janvier au 17 décembre 2025.

Les principales variables utilisées sont :

Colonne	Description	Utilisation
date	Date du signalement	KPI 1 – évolution mensuelle
cyberharcèlementType	Type de cyberviolence	KPI 2, 6b, 6c, 6f
plateforme	Plateforme concernée	KPI 3, 6c, 6d
genre	Genre de la victime	KPI 4, 6a, 6b, 6d, 6e
age	Tranche d'âge	KPI 4, 6a
anonymat	Signalement anonyme	KPI 5, 6e
accompagnement	Demande d'accompagnement	KPI 5, 6f
typeAccompagnement	Type d'aide demandée	Variable disponible pour analyse ultérieure
langue	Langue du signalement	Contrôle et normalisation

TABLE 1 – Variables exploitées dans le traitement

3. Nettoyage et préparation des données

Le nettoyage a été réalisé dans un script dédié **src/cleaning.py**. Les données brutes sont chargées depuis le fichier Excel situé dans **data/raw/**.

3.1 Étapes de nettoyage

Les opérations réalisées sont les suivantes :

1. Chargement du fichier Excel avec **pandas.read_excel()**.
2. Suppression des espaces superflus dans les variables textuelles.
3. Normalisation de la variable **accompagnement** en modalités Oui et Non.
4. Normalisation de la variable **langue** en minuscules.
5. Conversion de la variable **date** au format **datetime**.
6. Contrôle des dimensions et des valeurs après nettoyage.
7. Contrôle des valeurs manquantes.

8. Validation par assertions.
9. Sauvegarde du jeu nettoyé dans `data/processed/signalements_clean.csv`.

3.2 Contrôles réalisés

Le nombre de lignes reste égal à **138** après nettoyage. Le nettoyage ne supprime donc aucun signalement.

Les valeurs manquantes restent identifiées afin de ne pas introduire artificiellement des informations :

- **Genre** : 133 valeurs renseignées, soit 5 valeurs manquantes.
- **Âge** : 129 valeurs renseignées, soit 9 valeurs manquantes.

Les valeurs normalisées de langue sont **fr** et **ar**, tandis que les modalités d'accompagnement sont **Oui** et **Non**.

3.3 Chaîne de traitement

`signalements.xlsx` → `cleaning.py` → `signalements_clean.csv` → `kpi.py` →
KPI + graphiques

Cette séparation permet de distinguer les données brutes, les données préparées et les résultats analytiques.

4. Méthodologie de calcul des KPI

Les indicateurs définis au Jalon 1 sont organisés en deux familles :

- **Famille A** : répartitions simples, KPI 1 à KPI 5 ;
- **Famille B** : croisements entre deux variables, regroupés sous le KPI 6.

Pour les croisements, les pourcentages présentés sont des pourcentages en ligne :

$$\text{Pourcentage}_{ij} = \frac{\text{Effectif}_{ij}}{\text{Total de la ligne } i} \times 100.$$

Pour les tests d'indépendance, le seuil retenu est $\alpha = 0,05$. La condition définie au Jalon 1 exige que les effectifs théoriques soient supérieurs ou égaux à 5 dans au moins 80 % des cases.

Lorsque la condition du khi-deux n'est pas satisfaite, le test exact de Fisher est prévu comme test de repli lorsque son application est adaptée.

5. Résultats des indicateurs

5.1 KPI 1 – Volume mensuel des signalements

Le KPI 1 mesure le nombre de signalements enregistrés chaque mois en 2025.

Les résultats obtenus sont :

Mois	Nombre de signalements
Janvier	32
Février	31
Mars	9
Avril	2
Mai	0
Juin	0
Juillet	0
Août	0
Septembre	0
Octobre	0
Novembre	47
Décembre	17
Total	138

TABLE 2 – Volume mensuel des signalements en 2025

Le volume est particulièrement élevé en janvier et février, puis connaît une forte augmentation en novembre avec 47 signalements. Les mois de mai à octobre présentent aucun signalement dans le jeu étudié.

Volume mensuel des signalements EMC Helpline — 2025




FIGURE 1 – KPI 1 – Volume mensuel des signalements EMC Helpline en 2025

KPI 1 – Volume mensuel des signalements EMC Helpline en 2025 kpi1

5.2 KPI 2 – Répartition par type de cyberviolence

Le type **Autres** représente 51 signalements, soit 36,96 % du total. Il est suivi par la publication de photos intimes ou personnelles avec 33 signalements (23,91 %) et les propos de haine avec 21 signalements (15,22 %).

Type	Part
Autres	36,96 %
Publication de photos intimes ou personnelles	23,91 %
Propos de haine	15,22 %
Menace de publier des photos intimes ou personnelles	9,42 %
Diffamation	9,42 %
Propos raciste ou discriminatoire	3,62 %
Usurpation d'identité	0,72 %
Escroquerie	0,72 %

TABLE 3 – Répartition des signalements par type de cyberviolence




FIGURE 2 – KPI 2 – Répartition des signalements par type de cyberviolence

KPI 2 – Répartition des signalements par type de cyberviolence kpi2

5.3 KPI 3 – Répartition par plateforme

Facebook et Instagram représentent chacun 28,26 % des signalements. WhatsApp représente 25,36 % et TikTok 18,12 %.

Plateforme	Part
Facebook	28,26 %
Instagram	28,26 %
WhatsApp	25,36 %
TikTok	18,12 %

TABLE 4 – Répartition des signalements par plateforme

Répartition des signalements par plateforme — 2025




FIGURE 3 – KPI 3 – Répartition des signalements par plateforme

KPI 3 – Répartition des signalements par plateforme kpi3

5.4 KPI 4 – Répartition par genre et tranche d'âge

5.4.1 Genre

Sur les 133 signalements pour lesquels le genre est renseigné, 79 concernent des victimes de genre féminin (59,40 %) et 54 de genre masculin (40,60 %).

Répartition des signalements par genre — 2025




FIGURE 4 – KPI 4 – Répartition des signalements par genre

KPI 4 – Répartition des signalements par genre kpi4genre

5.4.2 Tranche d'âge

Sur les 129 signalements disposant d'une tranche d'âge, 69 concernent les 18–25 ans (53,49 %), 59 concernent les plus de 26 ans (45,74) 1 concerne la tranche 13–17 ans (0,78

Répartition des signalements par tranche d'âge — 2025




FIGURE 5 – KPI 4 – Répartition des signalements par tranche d'âge

KPI 4 – Répartition des signalements par tranche d'âge kpi4age

5.5 KPI 5 – Taux d'anonymat et de demande d'accompagnement

Sur les 138 signalements :

- 105 sont anonymes, soit un taux d'anonymat de **76,09 %** ;
- 32 correspondent à une demande d'accompagnement, soit **23,19 %**.

Ces deux indicateurs permettent de suivre simultanément la tendance à l'anonymat et l'expression d'un besoin de prise en charge.

Taux d'anonymat et de demande d'accompagnement — 2025




FIGURE 6 – KPI 5 – Anonymat et demande d'accompagnement

KPI 5 – Taux d'anonymat et de demande d'accompagnement kpi5

6. KPI 6 – Croisements entre variables

Le KPI 6 regroupe les croisements définis au Jalon 1. Ils permettent d'étudier les relations entre profils, types de cyberviolence, plateformes, anonymat et accompagnement.

6.1 KPI 6a – Âge × genre

Le tableau porte sur 129 observations renseignées simultanément.

Pour les 18–25 ans, 63,77 % sont de genre féminin et 36,23 % de genre masculin. Pour les plus de 26 ans, la répartition est de 52,54 % féminin contre 47,46 % masculin.

Le test du khi-deux donne :

- $\chi^2 = 2,3586$
- degrés de liberté = 2
- $p = 0,3075$
- 66,67 % des cases ont un effectif théorique ≥ 5 .

La condition de validité du khi-deux n'étant pas satisfaite, le résultat est interprété **descriptivement** et aucune conclusion statistique d'association n'est retenue.

Répartition du genre selon la tranche d'âge — 2025




FIGURE 7 – KPI 6a – Répartition du genre selon la tranche d'âge

KPI 6a – Répartition du genre selon la tranche d'âge kpi6a

6.2 KPI 6b – Type de cyberviolence × genre

Les catégories rares ont été regroupées afin d'améliorer les conditions d'application du test. Après regroupement, cinq catégories principales sont conservées : *Autres*, *Diffamation*, *Menace de publier des photos intimes ou personnelles*, *Propos de haine* et *Publication de photos intimes ou personnelles*.

Le test du khi-deux est alors valide avec 90 % des cases présentant un effectif théorique supérieur ou égal à 5.

Résultats :

- $\chi^2 = 6,9937$
- degrés de liberté = 4
- $p = 0,1362$
- V de Cramér = 0,2293.

La p-valeur étant supérieure à 0,05, aucune association statistiquement significative n'est mise en évidence entre le type de cyberviolence et le genre. Le V de Cramér indique une association de faible intensité.

Répartition du genre selon le type de cyberviolence — 2025




FIGURE 8 – KPI 6b – Répartition du genre selon le type de cyberviolence

KPI 6b – Répartition du genre selon le type de cyberviolence kpi6b

6.3 KPI 6c – Type de cyberviolence × plateforme

La première analyse a montré que la condition du khi-deux n'était pas respectée : 34,38 % seulement des cases présentaient un effectif théorique supérieur ou égal à 5.

Les catégories rares ont donc été regroupées en trois catégories principales : *Autres*, *Propos de haine* et *Publication de photos intimes ou personnelles*. Après regroupement, 91,67 % des cases satisfont la condition.

Les résultats du test sont :

- $\chi^2 = 12,5735$
- degrés de liberté = 6
- $p = 0,0503$
- V de Cramér = 0,2134.

La p-valeur est légèrement supérieure au seuil de 0,05. Le test ne permet donc pas de retenir une association statistiquement significative entre le type de cyberviolence et la plateforme. L'intensité mesurée par le V de Cramér est faible.

Répartition des plateformes selon le type de cyberviolence — 2025




FIGURE 9 – KPI 6c – Répartition du type de cyberviolence selon la plateforme

KPI 6c – Répartition du type de cyberviolence selon la plateforme kpi6c

6.4 KPI 6d – Plateforme × genre

Les 133 observations renseignées simultanément donnent les pourcentages suivants :

Plateforme	Féminin	Masculin
Facebook	61,11 %	38,89 %
Instagram	56,76 %	43,24 %
TikTok	72,00 %	28,00 %
WhatsApp	51,43 %	48,57 %

TABLE 5 – Répartition du genre selon la plateforme

La condition du khi-deux est totalement respectée : 100 % des cases ont un effectif théorique supérieur ou égal à 5.

Le test donne :

- $\chi^2 = 2,7188$
- degrés de liberté = 3
- $p = 0,4370$
- V de Cramér = 0,1430.

Aucune association statistiquement significative n'est détectée entre la plateforme et le genre. Le V de Cramér indique une association faible.

Répartition du genre selon la plateforme




FIGURE 10 – KPI 6d – Répartition du genre selon la plateforme

KPI 6d – Répartition du genre selon la plateforme kpi6d

6.5 KPI 6e – Anonymat × genre

Le croisement porte sur 133 observations renseignées.

Pour les signalements non anonymes, 65,62 % concernent le genre féminin et 34,38 % le genre masculin. Pour les signalements anonymes, ces proportions sont respectivement de 57,43 % et 42,57 %.

Le test exact de Fisher donne :

- odds ratio = 1,4154 ;
- $p = 0,536$.

La p-valeur étant supérieure à 0,05, aucune association statistiquement significative n'est mise en évidence entre l'anonymat et le genre.

Répartition du genre selon l'anonymat




FIGURE 11 – KPI 6e – Répartition du genre selon l'anonymat

KPI 6e – Répartition du genre selon l'anonymat kpi6e

6.6 KPI 6f – Accompagnement × type de cyberviolence

Ce croisement relie la demande d'accompagnement au type de cyberviolence subi.

Les pourcentages en ligne montrent notamment :

- **Autres** : 24,53 % de demandes d'accompagnement ;
- **Diffamation** : 7,69 % ;
- **Menace de publier des photos intimes ou personnelles** : 38,46 % ;
- **Propos de haine** : 33,33 % ;
- **Propos raciste ou discriminatoire** : 0 % ;
- **Publication de photos intimes ou personnelles** : 18,18 %.

La condition initiale du khi-deux n'est pas respectée. Après regroupement des catégories très rares, elle reste insuffisante avec **58,33 %** de cases ayant un effectif théorique supérieur ou égal à 5.

Par conséquent, le résultat doit être présenté comme **descriptif** tant que le test exact de Fisher adapté au tableau obtenu n'a pas été exécuté et validé.

Résultat statistique à compléter après validation du test de repli :

Test exact de Fisher – KPI 6f : à compléter après exécution du test exact adapté au tableau $R \times 2$.




FIGURE 12 – KPI 6f – Demande d'accompagnement selon le type de cyberviolence

KPI 6f – Demande d'accompagnement selon le type de cyberviolence kpi6f

7. Synthèse des résultats statistiques

KPI	Croisement	Test	<i>p</i>	Effet	Conclusion
6a	Âge × genre	χ^2 non retenu	0,3075	–	Interprétation descriptive
6b	Type × genre	χ^2 + V Cramér	0,1362	V=0,2293	Pas d'association significative
6c	Type × plateforme	χ^2 + V Cramér	0,0503	V=0,2134	Pas d'association significative au seuil 5 %
6d	Plateforme × genre	χ^2 + V Cramér	0,4370	V=0,1430	Pas d'association significative
6e	Anonymat × genre	Fisher	0,5360	OR=1,4154	Pas d'association significative
6f	Accompagnement × type	Fisher à valider	–	–	Interprétation descriptive à ce stade

TABLE 6 – Synthèse des analyses statistiques des croisements

Les résultats statistiques doivent être distingués des observations descriptives. Une différence visuelle entre deux catégories ne constitue pas à elle seule une preuve d'association statistique.

8. Validation des calculs

Une première validation a été réalisée en comparant les sorties du script avec les comptages directs obtenus à partir du fichier nettoyé.

Les contrôles principaux sont :

- total des signalements : **138** ;
- somme des KPI de répartition : **138** ;
- pourcentages des répartitions : **100 %** lorsque toutes les valeurs de la variable concernée sont renseignées ;
- genre : 79 féminin + 54 masculin = **133** ;
- âge : 69 + 59 + 1 = **129** ;
- anonymat : 105 signalements anonymes sur 138 ;
- accompagnement : 32 demandes sur 138 ;
- vérification des conditions du khi-deux pour chaque croisement concerné.

Ces contrôles permettent de vérifier que les calculs produits par `kpi.py` sont cohérents avec les données nettoyées.

9. Environnement technique

Le traitement a été réalisé avec une pile volontairement légère, conformément au document de cadrage du projet :

Outil	Utilisation
Python	Langage de développement
Pandas	Chargement, nettoyage et agrégation des données
Plotly	Production des graphiques interactifs
SciPy	Tests statistiques
Excel	Source initiale des données
CSV	Stockage intermédiaire des données nettoyées

TABLE 7 – Environnement technique du Jalon 2

10. Organisation des fichiers

L'organisation retenue est la suivante :

```
PFA_EMCMRPI/
|
+-- data/
|   +-- raw/
|       |   +-- signalements.xlsx
|       |
|       +-- processed/
|           +-- signalements_clean.csv
|
+-- src/
|   +-- cleaning.py
|   +-- kpi.py
|
+-- figures/
|   +-- KPI 1 ... KPI 6f
|
+-- rapport_jalon2.tex
```


La séparation entre **raw** et **processed** permet de conserver le fichier original et de travailler sur une version nettoyée reproductible.

11. Livrables produits au Jalon 2

Les éléments produits sont :

1. `src/cleaning.py` : script de nettoyage et de validation ;
2. `data/processed/signalements_clean.csv` : données nettoyées ;
3. `src/kpi.py` : calcul des KPI et production des graphiques ;
4. graphiques Plotly correspondant aux KPI ;
5. présent rapport de Jalon 2.

12. Conclusion

Le Jalon 2 a permis de transformer le jeu de données brut en un jeu de données nettoyé et exploitable, puis de calculer les indicateurs définis au Jalon 1.

Les 138 signalements ont été conservés après nettoyage. Les principales incohérences de format ont été normalisées et les valeurs manquantes ont été contrôlées.

Les KPI 1 à 5 permettent de décrire le volume, les types de cyberviolence, les plateformes, le profil démographique, l'anonymat et la demande d'accompagnement. Les croisements du KPI 6 apportent une analyse plus fine des relations entre ces variables.

Les tests statistiques réalisés montrent notamment qu'aucune association statistiquement significative n'est retenue pour les croisements 6b, 6c, 6d et 6e aux seuils utilisés. Lorsque les conditions du khi-deux ne sont pas satisfaites, l'analyse est maintenue à un niveau descriptif ou un test de repli est prévu.